UNIVERSIDADE DO ESTADO DE SANTA CATARINA — UDESC

CENTRO DE CIÊNCIAS TECNOLÓGICAS — CCT

PROGRAMA DE PÓS-GRADUAÇÃO EM COMPUTAÇÃO APLICADA — PPGCAP

MESTRADO ACADÊMICO EM COMPUTAÇÃO APLICADA

LINHA DE PESQUISA: METODOLOGIA E TÉCNICAS DE COMPUTAÇÃO (MTC)

ANALÍTICA PRESCRITIVA E INTELIGÊNCIA ARTIFICIAL EXPLICÁVEL PARA A GESTÃO DE FROTA VEICULAR NO SETOR PÚBLICO

Estudo comparativo com dados de manutenção, patrimônio e abastecimento

FLORIANÓPOLIS — SC

2026

RESUMO

A gestão de frotas públicas reúne informações dispersas em cadastros patrimoniais, registros de manutenção e comprovantes de abastecimento. A fragmentação dificulta estimar risco de falha, custo operacional e prioridade de intervenção, e limita a conversão de previsões em decisões justificáveis. Este anteprojeto propõe desenvolver e avaliar uma arquitetura de analítica prescritiva, com inteligência artificial explicável, para apoiar a programação de manutenção preventiva e o planejamento de custos de uma frota institucional. Serão integradas, mediante autorização, extrações administrativas de patrimônio, manutenção e abastecimento, com identificação pseudonimizada dos veículos e alinhamento temporal. Serão comparados, sem uso de regressão linear, múltiplos métodos para tarefas de classificação de risco e regressão de consumo/custo, incluindo Random Forest, Extra Trees, Gradient Boosting/HistGradientBoosting, XGBoost quando disponível e Support Vector Regression com kernel RBF. A explicabilidade será examinada por SHAP, LIME e importância por permutação. Em seguida, as previsões alimentarão um modelo de otimização inteira mista para priorizar intervenções sob limites de orçamento, horas de oficina e elegibilidade operacional; a política otimizada será comparada com a prática histórica e regras heurísticas. A avaliação empregará validação temporal, métricas adequadas a dados desbalanceados e regressão, comparação estatística pareada, análise de sensibilidade e avaliação da qualidade das explicações. O estudo não presume acesso já concedido nem promete economia causal: a unidade de análise e o horizonte dependerão da disponibilidade, qualidade e autorização dos dados. Espera-se produzir evidência comparativa, um artefato computacional auditável e recomendações condicionadas aos limites empíricos do caso.

Palavras-chave: analítica prescritiva; gestão de frotas; manutenção preditiva; inteligência artificial explicável; otimização; setor público.

1 INTRODUÇÃO

A gestão de uma frota institucional exige conciliar disponibilidade dos veículos, segurança, manutenção, consumo de combustível e limites orçamentários. Essas dimensões deixam vestígios em sistemas distintos: o cadastro patrimonial identifica características e situação do bem; as ordens de serviço registram intervenções, falhas e custos; e os abastecimentos informam volume, valor e, em alguns casos, hodômetro. Sem integração temporal e sem uma chave confiável de veículo, a administração tende a analisar os dados em relatórios isolados,

dificultando detectar padrões de desgaste ou comparar o custo de operação entre unidades e períodos.

A literatura de manutenção preditiva veicular reúne métodos de aprendizado de máquina, dados de sensores e históricos de oficina, mas destaca desafios de qualidade, integração e explicabilidade. Uma revisão sistemática recente sobre manutenção preditiva em veículos examina 94 estudos e aponta que a disponibilidade de dados e a adoção de XAI permanecem questões relevantes (MAHALE; KOLHAR; MORE, 2025). Em estudo empírico com caminhões, modelos de floresta aleatória, XGBoost, redes neurais e combinação de modelos foram comparados para estimar custos por distância, ilustrando tanto a viabilidade de modelos não lineares quanto a relevância de dados reais e validação em veículos não vistos (KATREDDI et al., 2023).

Prever um risco ou um custo não determina, por si só, qual intervenção deve ser executada. Analítica prescritiva associa estimativas a decisões sujeitas a objetivos e restrições; sua qualidade deve ser medida pelo desempenho da política, e não apenas pelo erro preditivo (BERTSIMAS; KALLUS, 2020). Neste estudo, a previsão de risco e custo será integrada a uma recomendação de priorização de manutenção, com limites explícitos de orçamento e capacidade. As previsões de combustível serão usadas para caracterizar a operação e apoiar o planejamento orçamentário. Só será atribuído efeito de uma manutenção sobre o consumo se os dados e o desenho empírico permitirem sustentar essa relação.

A pesquisa mantém o enquadramento em Computação Aplicada e na linha de Metodologia e Técnicas de Computação (MTC), deslocando o objeto do projeto original — analítica ampla para processos administrativos — para um caso delimitado de frota. O recorte aplicado será definido junto ao órgão custodiante, preferencialmente no contexto da administração pública estadual de Santa Catarina, condicionado à autorização formal de acesso e à viabilidade dos registros disponíveis.

1.1 Problema de pesquisa

Como integrar dados de patrimônio, manutenção e abastecimento para comparar modelos não lineares de previsão e métodos de explicabilidade e, a partir deles, gerar e avaliar recomendações de manutenção para uma frota pública sob restrições de custo, capacidade de oficina e segurança?

1.2 Hipóteses de trabalho

1. H1 — A integração de atributos patrimoniais, históricos de manutenção e medidas de abastecimento melhora, em comparação com modelos treinados apenas com manutenção, pelo menos uma métrica principal de previsão fora do tempo de treinamento; a magnitude e a incerteza dessa diferença serão reportadas.
2. H2 — Ensembles de árvores (Random Forest, Extra Trees e Gradient Boosting) apresentam desempenho competitivo frente a SVR-RBF em dados tabulares da frota; não se pressupõe previamente um vencedor.
3. H3 — Sob o mesmo orçamento, capacidade e nível de risco admissível, a política de otimização reduz o custo total esperado no experimento retrospectivo em relação à prática reconstruída e a regras heurísticas. A conclusão será descrita como contrafactual simulado, salvo validação prospectiva ou evidência causal.
4. H4 — As explicações SHAP e LIME podem representar fatores locais e globais das previsões com fidelidade e estabilidade suficientes para revisão por especialistas; a sua utilidade não será inferida apenas por gráficos de importância.

2 JUSTIFICATIVA

A relevância científica decorre da avaliação conjunta de três camadas que frequentemente são estudadas em separado: integração de dados administrativos da frota; comparação controlada de modelos preditivos; e otimização de decisões apoiada por explicações. A contribuição não será simplesmente aplicar um classificador, mas documentar como as escolhas de preparação dos dados, validação temporal, representação do risco e restrições operacionais alteram as recomendações.

A relevância institucional está em apoiar priorização transparente quando vários veículos disputam orçamento e horas de oficina. Uma estimativa calibrada de risco pode antecipar inspeções, enquanto previsões de custo e abastecimento podem qualificar cenários orçamentários. As recomendações permanecerão como apoio ao gestor e não substituirão critérios de segurança, normas do fabricante, decisões de manutenção obrigatória ou julgamento técnico.

A justificativa de XAI é especialmente importante quando modelos não lineares são usados para orientar decisões sobre bens públicos. SHAP distribui a contribuição das variáveis para cada predição dentro de uma estrutura aditiva, enquanto LIME aproxima localmente o comportamento do modelo por um explicador simples (LUNDBERG; LEE, 2017; RIBEIRO; SINGH; GUESTRIN, 2016). As explicações serão apresentadas como evidência sobre o comportamento do modelo, não como prova causal.

A execução depende de viabilidade documental: autorização do órgão, definição do período, dicionário de dados, qualidade da identificação de veículos e cobertura suficiente de hodômetro, abastecimentos e ordens de serviço. Se não houver variável confiável de falha ou de manutenção corretiva, o desfecho será reformulado para estimar a ocorrência registrada de serviço não programado ou o intervalo/custo até o próximo evento, sem alegar falha mecânica não observada.

3 OBJETIVOS

3.1 Objetivo geral

Desenvolver e avaliar uma arquitetura computacional de analítica prescritiva e IA explicável para apoiar a gestão de frota veicular pública, integrando dados de patrimônio, manutenção e abastecimento e comparando múltiplos algoritmos não lineares quanto à previsão, explicabilidade e qualidade das decisões recomendadas.

3.2 Objetivos específicos

- Caracterizar as fontes, o período, a unidade de análise, os identificadores e as limitações dos arquivos de cadastro patrimonial, manutenção e abastecimento autorizados para a pesquisa.
- Construir uma base analítica longitudinal por veículo e período, com regras rastreáveis de integração, validação de hodômetro, tratamento de faltantes e proteção de dados.
- Definir alvos mensuráveis para risco de manutenção registrada e consumo/custo operacional, evitando vazamento temporal e escolhendo horizontes compatíveis com a periodicidade dos registros.
- Treinar e comparar, sem regressão linear, pelo menos quatro métodos por tarefa compatível: Random Forest, Extra Trees, Gradient Boosting/HistGradientBoosting, XGBoost se disponível, e SVM/SVR com kernel RBF; comparar também uma referência ingênua ou regra operacional.
- Avaliar SHAP, LIME e importância por permutação em explicações globais e locais, medindo fidelidade, estabilidade e legibilidade junto a avaliadores técnicos quando viável.
- Formular um problema de otimização inteira mista para priorizar manutenção em períodos sucessivos, sujeito a orçamento, capacidade de oficina, elegibilidade e requisitos obrigatórios.
- Comparar a política otimizada com a prática histórica reconstruída, uma regra por limiar de risco e uma heurística de prioridade risco-custo, reportando custo esperado, risco residual, intervenções e sensibilidade.
- Produzir documentação reprodutível do pipeline, modelos, pressupostos, métricas, explicações, riscos de privacidade e limites de validade externa.

4 FUNDAMENTAÇÃO TEÓRICA

4.1 Dados integrados e ciclo de vida da frota

O cadastro patrimonial oferece atributos relativamente estáveis — classe, marca/modelo, ano, combustível, situação, unidade, data de incorporação e eventual valor contábil — e permite definir a população de veículos elegíveis. Os registros de manutenção adicionam data, hodômetro, tipo de serviço, natureza preventiva/corretiva, componentes, custo, duração e oficina, quando disponíveis. Os abastecimentos podem conter data, litros, valor, combustível, hodômetro, posto e indicação de tanque completo. A integração requer uma chave harmonizada e um calendário consistente; duplicidades, mudanças de identificador, registros sem hodômetro e diferenças de granularidade serão documentados.

A informação de abastecimento, isoladamente, não garante consumo real. O cálculo litros/quilômetro exige leituras sucessivas e coerentes do odômetro e, idealmente, abastecimentos de tanque completo ou uma agregação que reduza o erro de abastecimentos parciais. Se essa condição não estiver disponível, a pesquisa usará uma medida agregada de litros ou custo por intervalo/veículo, qualificando-a como proxy e não como eficiência física precisa. A mesma cautela vale para custo de manutenção por quilômetro: só será calculado em intervalos com distância válida.

4.2 Aprendizado de máquina para previsão

Modelos baseados em árvores particionam o espaço de atributos e capturam interações e não linearidades sem exigir uma forma funcional linear. Random Forest agrega árvores treinadas com amostras e subconjuntos aleatórios de atributos (BREIMAN, 2001); Extra Trees amplia a aleatorização dos cortes (GEURTS; ERNST; WEHENKEL, 2006); Gradient Boosting ajusta sequencialmente árvores para reduzir o erro (FRIEDMAN, 2001), e XGBoost é uma implementação de boosting com regularização e otimizações computacionais (CHEN; GUESTRIN, 2016). SVM com kernel RBF e SVR oferecem comparação baseada em margens e funções de similaridade não lineares (CORTES; VAPNIK, 1995). Esses métodos são candidatos, não garantias de superioridade: a comparação empírica é central.

Os problemas serão separados por finalidade. Classificação estimará a probabilidade de um evento de manutenção corretiva ou não programada em horizonte fixo; regressão estimará custo normalizado ou consumo. Se a qualidade temporal e o volume permitirem, poderá haver previsão de demanda mensal por classe de veículo e combustível, comparada com referência

sazonal e modelos com atributos defasados. As saídas não serão misturadas: um AUC alto na classificação não equivale a baixo erro de custo nem a melhor decisão.

4.3 Analítica prescritiva e otimização

Na formulação prescritiva, o modelo de aprendizado fornece probabilidades, custos e parâmetros que alimentam uma decisão sujeita a recursos limitados. Bertsimas e Kallus (2020) formalizam essa passagem como otimização estocástica condicionada a informações preditivas e defendem avaliar políticas pela qualidade operacional da decisão. Para a frota, o problema será programar quais veículos receberão manutenção preventiva em quais períodos, evitando que a previsão seja tratada como uma ordem automática.

A função objetivo deve explicitar custos de intervenção, risco de falha, indisponibilidade e penalidades por manutenção obrigatória vencida. Limites de orçamento e horas de oficina evitam recomendações inviáveis. Uma política retrospectiva pode parecer econômica por usar informação que não existia no momento da decisão; por isso, a simulação reconstruirá apenas as variáveis observáveis até cada data de corte e reportará a natureza contrafactual do resultado.

4.4 IA explicável e governança

SHAP será empregado para decomposição local e agregação global; LIME, para aproximar predições em vizinhanças de casos selecionados; e a importância por permutação, como comparação model-agnostic. A pesquisa confrontará divergências entre métodos e verificará a consistência das explicações em reamostragens ou pequenas perturbações plausíveis. As explicações não revelam causalidade e podem ser instáveis quando as variáveis são correlacionadas. Relatórios do modelo descreverão população, finalidade, dados, métricas, limites e condições de uso.

Dados de frota podem conter elementos associados a servidores ou condutores. A pesquisa aplicará minimização de dados, pseudonimização de identificadores, controle de acesso, armazenamento seguro e retenção limitada; variáveis pessoais não necessárias serão excluídas. A autorização institucional, o enquadramento ético e a conformidade com a Lei Geral de Proteção de Dados (Lei nº 13.709/2018) serão verificados antes do tratamento analítico. A pseudonimização não equivale a anonimização irreversível.

5 METODOLOGIA E SOLUÇÃO PROPOSTA

5.1 Delineamento

Pesquisa aplicada, quantitativa, com estudo de caso instrumental e desenvolvimento/avaliação de artefato computacional. O fluxo de trabalho seguirá etapas compatíveis com CRISP-DM: compreensão do problema, compreensão dos dados, preparação, modelagem, avaliação e implantação experimental em modo retrospectivo ou sombra (SHEARER, 2000). A unidade de análise será veículo-período, com grão temporal mensal ou intervalo entre eventos determinado após inspeção dos registros. O caso será realizado com uma frota institucional de órgão público a ser formalmente definido; a referência à administração estadual de Santa Catarina permanece como cenário prioritário, condicionada à autorização de acesso.

5.2 Fontes e preparação dos dados

Serão solicitados, preferencialmente em extrações CSV/XLSX ou acesso controlado ao banco, três grupos de arquivos: (i) patrimônio: código interno, categoria, fabricante/modelo, ano, combustível, situação, lotação e datas relevantes; (ii) manutenção: veículo, abertura/fechamento, hodômetro, descrição/categoria, preventiva/corretiva, custo de peças e serviço, duração e oficina; (iii) abastecimento: veículo, data, litros, preço/valor, combustível, hodômetro, posto e indicador de tanque completo. O conjunto mínimo e o período serão definidos pelo dicionário efetivamente recebido, não presumidos neste anteprojeto.

A preparação incluirá padronização de chaves e unidades, deduplicação, verificação de datas e hodômetros monotônicos, detecção de litros/valores fora de faixa, conciliação de códigos de combustível, identificação de intervalos sem distância válida e criação de variáveis defasadas. Todas as transformações serão ajustadas somente no conjunto de treino quando envolverem parâmetros estimados. Imputação, codificação e seleção de atributos serão encapsuladas na pipeline para evitar contaminação entre treino e teste.

Variáveis derivadas candidatas incluem idade e classe do veículo, quilômetros desde a última manutenção, número e custo de serviços em janelas passadas, proporção de eventos corretivos, tempo desde a última intervenção, consumo observado por intervalo, litros e gasto por veículo/mês e sazonalidade. Custos poderão ser corrigidos pelo índice escolhido e pela data-base, se a série permitir; a escolha e a justificativa serão documentadas. Dados futuros, como custo de ordem ainda não encerrada, serão excluídos dos atributos usados em previsões emitidas antes da intervenção.

5.3 Tarefas preditivas e algoritmos comparados

A tabela resume a matriz experimental planejada. O conjunto final de candidatos será restringido por disponibilidade, volume, cobertura das classes e custo computacional. Em cada tarefa haverá busca de hiperparâmetros dentro dos dados de treino e comparação com linha de base apropriada. Não será usado o modelo de regressão linear. Regressão SVR não é regressão linear: usa função kernel RBF; ainda assim, o termo "regressão linear" será excluído para atender ao recorte solicitado.

Tarefa e alvo	Candidatos não lineares	Referência e métricas principais
Risco de manutenção corretiva no horizonte H: evento binário por veículo-período. H será escolhido com gestores e distribuição dos registros.	Random Forest Classifier; Extra Trees Classifier; Gradient Boosting/HistGradientBoosting; XGBoost Classifier se disponível; SVC com kernel RBF.	Regra histórica/limiar e classificador ingênuo. PR-AUC, recall, precisão, F1, Brier e calibração; matriz de confusão no limiar operacional.
Custo normalizado de manutenção: R$/1.000 km ou custo por veículo-mês, conforme cobertura de hodômetro.	Random Forest Regressor; Extra Trees Regressor; HistGradientBoosting/Gradient Boosting Regressor; XGBoost Regressor se disponível; SVR-RBF.	Mediana histórica por classe e período como baseline. MAE, RMSE, R^2 e erro absoluto por classe; MAPE só se alvo estritamente positivo e longe de zero.
Consumo/dispêndio de combustível: L/100 km apenas quando odômetros/tanque permitirem; caso contrário, litros ou R$/veículo-período.	Random Forest Regressor; Extra Trees Regressor; Gradient Boosting/HistGradientBoosting; XGBoost; SVR-RBF. Para previsão mensal: árvores com lags e referência sazonal; ETS/SARIMA somente se houver série suficiente.	Persistência ou média sazonal. MAE, RMSE e sMAPE com cautela; comparação por veículo e horizonte.
Recomendação de manutenção preventiva por período, com orçamento e horas de oficina.	Programação inteira mista (MILP) com solver disponível; CP-SAT como formulação alternativa quando compatível; heurística gulosa risco-custo e regra por limiar.	Política histórica reconstruída, regra de risco e baseline "não alterar". Custo esperado, risco residual, veículos intervencionados, horas e violações.
Explicação das previsões selecionadas.	SHAP; LIME; importância por permutação. Aplicação sobre modelos campeões e amostra de casos de alto/baixo risco.	Fidelidade local, estabilidade sob perturbações, concordância entre métodos e revisão interpretativa por especialistas, se viável.

A seleção de H (por exemplo, próximo mês, 30 dias ou uma faixa de quilômetros) não será fixada sem conhecer a cadência dos registros e a utilidade operacional. O rótulo será "manutenção corretiva/não programada registrada", não "falha" em sentido mecânico, a menos que a base permita distinguir falha confirmada de serviço ordinário. Caso a classe positiva seja rara, será reportada a prevalência e usada PR-AUC; ajuste de pesos ou limiar será feito apenas no treino/validação.

5.4 Formulação matemática da decisão

Considere $i = 1,\ldots,N$ veículos e $t = 1,\ldots,T$ períodos. Seja $x_{it} = 1$ se a manutenção preventiva do veículo i for programada no período t e 0 caso contrário. Seja p^0_{it} a probabilidade de evento corretivo sem intervenção, estimada pelo modelo; p^1_{it} a probabilidade residual sob

intervenção; c^{M}_{it} o custo da manutenção programada; c^{f}_{it} o custo de reparo corretivo; c^{D}_{it} o custo de indisponibilidade, se puder ser estimado; h_{it} as horas de oficina; B_t o orçamento disponível; H_t a capacidade de oficina; e $e_{it} \in \{0,1\}$ um indicador de elegibilidade.

O problema inicial de programação será:

$$\text{minimizar} \quad \Sigma_i \Sigma_t \left[c^{M}_{it}\, x_{it} + ((1 - x_{it})p^{0}_{it} + x_{it}p^{1}_{it})(c^{f}_{it} + c^{D}_{it})\right]$$

$$\text{sujeito a:} \quad \Sigma_i\, c^{M}_{it}\, x_{it} \le B_t; \quad \Sigma_i\, h_{it}\, x_{it} \le H_t; \quad x_{it} \le e_{it}; \quad x_{it} \in \{0,1\}.$$

Regras obrigatórias do fabricante/segurança serão representadas como restrições de elegibilidade e prazos, após validação por responsáveis técnicos. A eficácia da intervenção η_{it} pode ser expressa por $p^{1}_{it} = (1 - \eta_{it})p^{0}_{it}$. Se η não puder ser estimada com dados observacionais comparáveis, não será apresentada como fato: serão executados cenários de sensibilidade (por exemplo, eficácia baixa, moderada e alta), com limites claramente identificados. Assim se evita converter associação histórica entre manutenção e falha em efeito causal sem desenho apropriado.

As previsões de combustível servirão para projeção de despesa e análise por veículo/classe. Não se incluirá combustível no objetivo como se a programação de manutenção reduzisse consumo sem evidência de efeito. Caso dados permitam estimar diferenças antes/depois com controle de sazonalidade, intensidade de uso e outros confundidores, essa análise será secundária e explicitamente observacional. A solução MILP será comparada a CP-SAT/heurísticas sob os mesmos parâmetros, orçamento e informações disponíveis em cada data de corte.

5.5 Validação e análises matemáticas

A divisão treino-validação-teste respeitará o tempo: períodos mais antigos treinam, períodos subsequentes selecionam hiperparâmetros e o bloco mais recente fica retido para teste final. Serão repetidas origens móveis (rolling-origin) quando houver extensão temporal suficiente. Sempre que vários registros de um mesmo veículo puderem aparecer em ambos os lados, serão reportados resultados com separação temporal e análise por grupos de veículos, para distinguir generalização para o futuro da generalização para veículos não observados. Em séries temporais, embaralhamento aleatório pode inflar o desempenho por permitir que informação temporalmente próxima apareça nos conjuntos de treino e teste; a validação temporal é, portanto, necessária (SCIKIT-LEARN, s.d.).

Para regressão, sejam y_j o valor observado e $\hat{y}_j$ a previsão, para n observações de teste:

$$\mathrm{MAE} = (1/n)\ \Sigma_j\ |y_j - \hat{y}_j|; \quad \mathrm{RMSE} = \sqrt{[(1/n)\ \Sigma_j\ (y_j - \hat{y}_j)^2]}; \quad R^2 = 1 - \Sigma_j(y_j - \hat{y}_j)^2\ /\ \Sigma_j(y_j - \bar{y})^2.$$

MAE resume erro absoluto na unidade do desfecho; RMSE penaliza mais erros grandes; R^2 mede variação explicada relativamente à média do conjunto de teste, podendo ser negativo fora da amostra. MAPE não será usada quando y=0 ou próximo de zero. Se aplicável, sMAPE será reportada como medida complementar e acompanhada de MAE em unidade natural.

Para classificação, a matriz de confusão determina VP, FP, VN e FN. Precisão = VP/(VP+FP); recall = VP/(VP+FN); F1 = 2·precisão·recall/(precisão+recall). A área sob a curva precisão-recall é prioritária quando positivos são raros. Para probabilidades p_j e rótulos $z_j \in \{0,1\}$, o escore de Brier é $BS = (1/n)\Sigma_j(p_j - z_j)^2$. A calibração será examinada por agrupamento de probabilidades e inclinação/intercepto, sem selecionar limiar no conjunto de teste.

A otimização será avaliada em simulação retrospectiva por custo esperado, risco residual ponderado, quantidade de ações e aderência aos limites. Uma métrica operacional comparativa será $\Delta = (C_base - C_política)/C_base$, em que C inclui apenas parcelas com definição e cobertura adequadas. Δ é uma diferença simulada com as hipóteses declaradas e não uma estimativa de economia efetivamente realizada. Serão apresentados intervalos de confiança obtidos por reamostragem em blocos ou por veículo quando apropriado e análise de sensibilidade para orçamento, horas de oficina, limiar de risco e eficácia da manutenção.

Para comparar modelos, cada método será avaliado nos mesmos blocos temporais. Serão apresentados média/mediana, dispersão e diferenças pareadas com intervalo de confiança; teste de Wilcoxon pareado poderá ser utilizado se o número e a independência efetiva dos blocos forem adequados, com correção de Holm para comparações múltiplas. A relevância prática e a calibração terão peso junto ao valor-p. A análise de ablação comparará atributos de manutenção apenas, patrimônio + manutenção e integração completa; nenhuma melhoria será afirmada antecipadamente.

5.6 Explicabilidade e avaliação humana

Para o modelo selecionado por tarefa, SHAP fornecerá decomposições locais e sumários globais, LIME produzirá aproximações locais para casos representativos e de maior risco, e permutação oferecerá uma referência global independente da arquitetura. A decomposição SHAP será expressa como $f(x) = E[f(X)] + \Sigma_j\ \varphi_j$, onde φ_j representa a contribuição atribuída ao atributo j para a predição x. A pesquisa comparará rankings globais e explicações de casos;

mensurará fidelidade local do surrogate LIME no entorno avaliado, estabilidade das importâncias a reamostragens e sensibilidade a atributos correlacionados. Gestores/mecânicos poderão avaliar clareza, plausibilidade operacional e utilidade com roteiro estruturado, sem apresentar a explicação como causalidade.

5.7 Ética, privacidade e reprodutibilidade

Antes da extração, serão definidos finalidade, controlador/custodiante, base legal aplicável e condições de compartilhamento com as unidades competentes. IDs de veículo e, se inevitável, de unidade serão pseudonimizados; identificadores de servidores/condutores e texto livre com dados pessoais serão excluídos ou tratados sob protocolo específico. O acesso será restrito, com registro de versão e linhagem das transformações; resultados públicos serão agregados para reduzir reidentificação. A necessidade de apreciação ética será consultada junto às instâncias responsáveis. O pipeline, configurações e métricas serão documentados com dados sintéticos ou exemplos não sensíveis quando a publicação da base real não for autorizada.

6 RESULTADOS ESPERADOS E CONTRIBUIÇÕES

Espera-se obter uma base analítica longitudinal documentada e uma arquitetura experimental que conecte as três fontes administrativas, respeitando a qualidade observada e as regras de proteção de dados. A pesquisa apresentará uma comparação reprodutível de algoritmos não lineares por tarefa, incluindo métricas fora do tempo de treinamento, explicações locais/globais e análise de estabilidade. O resultado pode revelar que uma família de modelos é superior em determinada tarefa, que não há diferença material ou que dados insuficientes impedem comparação conclusiva; todos são resultados cientificamente válidos.

O artefato prescritivo deverá produzir cenários de priorização de manutenção coerentes com limites de orçamento e capacidade e comparáveis à prática histórica e a heurísticas. A principal contribuição metodológica será explicitar as condições sob as quais essas recomendações são válidas: horizonte, cobertura dos dados, tratamento de rótulos, parâmetros de eficácia e restrições. A contribuição aplicada será um protótipo de suporte à decisão ou relatório reproduzível, sem implantação automática em produção e sem substituição da decisão humana.

Como produtos acadêmicos, prevê-se a dissertação, repositório de código sem dados restritos, documentação técnica do modelo/explicações e submissão de pelo menos um artigo

científico, condicionada aos resultados e às regras do programa. Nenhum ganho financeiro ou percentual de economia é antecipado.

7 LIMITAÇÕES, RISCOS E MITIGAÇÕES

Risco ou limitação	Efeito potencial	Mitigação prevista
Acesso formal aos três arquivos não concedido ou autorização tardia.	Impossibilidade de estudo de caso ou redução do escopo.	Formalizar consulta institucional no início; negociar base agregada ou amostra pseudonimizada; se inviável, reformular para dados públicos/abertos e declarar a mudança.
Chaves distintas, hodômetros ausentes ou inconsistentes.	Junções erradas e alvos de consumo/custo imprecisos.	Auditar cobertura, reconciliar chaves com custodiante, excluir intervalos inválidos e manter análises alternativas por veículo/período.
Rótulos raros ou ambíguos de falha.	Baixo poder preditivo e métricas instáveis.	Definir evento com especialista; usar PR-AUC/calibração; reportar prevalência; ajustar alvo para manutenção corretiva registrada, não falha mecânica.
Poucos veículos ou pouco histórico.	Sobreajuste e baixa validade externa.	Reduzir número de parâmetros, priorizar modelos tabulares, comparar por grupos/períodos e declarar insuficiência de evidência.
Eficácia causal da manutenção não identificável.	Custo otimizado excessivamente otimista.	Usar cenários de eficácia, reportar análise de sensibilidade e não alegar economia real sem validação prospectiva/quase-experimental.
Dados pessoais embutidos em texto livre ou vínculos.	Risco de exposição e desconformidade.	Minimização, revisão de campos, pseudonimização, acesso restrito e validação institucional/ética antes da extração.

8 CRONOGRAMA PROPOSTO

Planejamento estimado para 24 meses, ajustável ao calendário do PPGCAP e à data efetiva de ingresso. A solicitação de acesso e a análise de privacidade iniciam-se antes da coleta e condicionam as etapas empíricas.

Atividade	M1–3	M4–6	M7–9	M10–12	M13–15	M16–18	M19–21	M22–24
Revisão bibliográfica e delimitação do caso	•	•						
Autorização, governança, dicionário e diagnóstico dos dados	•	•	•					
Integração, limpeza e engenharia de atributos		•	•	•				
Modelagem preditiva, ajuste e validação temporal				•	•	•		
XAI, testes de estabilidade e avaliação com especialistas					•	•	•	
Otimização, cenários e comparação de políticas					•	•	•	
Análise estatística, escrita e submissão de artigo						•	•	•
Redação final, revisão, defesa e entrega							•	•

REFERÊNCIAS

BERTSIMAS, Dimitris; KALLUS, Nathan. From predictive to prescriptive analytics. Management Science, v. 66, n. 3, p. 1025–1044, 2020. DOI: https://doi.org/10.1287/mnsc.2018.3253.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 11 out. 2026.

BREIMAN, Leo. Random forests. Machine Learning, v. 45, p. 5–32, 2001. DOI: https://doi.org/10.1023/A:1010933404324.

CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: a scalable tree boosting system. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016. Proceedings [...]. New York: ACM, 2016. p. 785–794. DOI: https://doi.org/10.1145/2939672.2939785.

CORTES, Corinna; VAPNIK, Vladimir. Support-vector networks. Machine Learning, v. 20, p. 273–297, 1995. DOI: https://doi.org/10.1007/BF00994018.

FRIEDMAN, Jerome H. Greedy function approximation: a gradient boosting machine. The Annals of Statistics, v. 29, n. 5, p. 1189–1232, 2001. DOI: https://doi.org/10.1214/aos/1013203451.

GEURTS, Pierre; ERNST, Damien; WEHENKEL, Louis. Extremely randomized trees. Machine Learning, v. 63, p. 3–42, 2006. DOI: https://doi.org/10.1007/s10994-006-6226-1.

KATREDDI, Sasanka; THIRUVENGADAM, Arvind; THOMPSON, Gregory; SCHMID, Natalia; PADMANABHAN, Vishnu. Machine learning models for maintenance cost estimation in delivery trucks using diesel and natural gas fuels. Frontiers in Mechanical Engineering, v. 9, art. 1201068, 2023. DOI: https://doi.org/10.3389/fmech.2023.1201068.

LUNDBERG, Scott M.; LEE, Su-In. A unified approach to interpreting model predictions. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017. Proceedings [...]. 2017. Disponível em: https://arxiv.org/abs/1705.07874. Acesso em: 11 out. 2026.

MAHALE, Yashashree; KOLHAR, Shrikrishna; MORE, Anjali S. A comprehensive review on artificial intelligence driven predictive maintenance in vehicles: technologies, challenges and future research directions. Discover Applied Sciences, v. 7, art. 243, 2025. DOI: https://doi.org/10.1007/s42452-025-06681-3.

RIBEIRO, Marco Tulio; SINGH, Sameer; GUESTRIN, Carlos. “Why should I trust you?”: explaining the predictions of any classifier. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016. Proceedings [...]. New York: ACM, 2016. p. 1135–1144. DOI: https://doi.org/10.1145/2939672.2939778.

SCIKIT-LEARN DEVELOPERS. Cross-validation: evaluating estimator performance — time series split. Documentação técnica. Disponível em: https://scikit-learn.org/stable/modules/cross_validation.html#time-series-split. Acesso em: 11 out. 2026.

SHEARER, Colin. The CRISP-DM model: the new blueprint for data mining. Journal of Data Warehousing, v. 5, n. 4, p. 13–22, 2000.