UNIVERSIDADE DO ESTADO DE SANTA CATARINA • CENTRO DE CIÊNCIAS TECNOLÓGICAS (CCT) • PPGCAP

RELATÓRIO TÉCNICO DE PROCESSAMENTO, MANIPULAÇÃO E CRUZAMENTO DE DADOS

Stack Computacional, Especificações de Hardware, Engenharia de Dados Multimodal, Protocolos de Cruzamento Relacional e Testes Estatísticos

Autor: Eduardo Lopes Jonker
Orientação: Profa. Dra. Vivian Cremer Kalempa
Coorientação: Prof. Dr. Yuri Kaszubowski Lopes
Linha de Pesquisa: Metodologia e Técnicas de Computação
Órgão Auditado: SEA/SC (DITI / GFI)
Data de Consolidação: Outubro / 2026

VOLUME DE REGISTROS	INTEGRIDADE REFERENCIAL	DESDUPLICAÇÃO NLP	EFICIÊNCIA DE MEMÓRIA
350.737 OSs	**99,84%**	**80.000 Descritores**	**8,4 GB Pico**
1.636.541 itens de manutenção	Chaves primárias pareadas	Clusterizados em 7 sistemas	Dtypes vetorizados e batching

1. ARQUITETURA DE HARDWARE E INFRAESTRUTURA COMPUTACIONAL

Para processar a volumetria integral de 350.737 ordens de serviço e mais de 1,6 milhão de itens analíticos sem perda de desempenho, o ambiente de experimentação foi configurado sobre uma estação de trabalho dedicada, com processamento híbrido multicore, alocação de memória primária de alta largura de banda e partição NVMe estendida para contenção de sobrecarga (*Out-Of-Memory*):

COMPONENTE DE HARDWARE	ESPECIFICAÇÃO TÉCNICA OPERACIONAL	FUNÇÃO NO PROCESSAMENTO
Equipamento / Host	Dell Inspiron 15 3530 (Arquitetura x86_64 Little Endian)	Estação de execução do pipeline local
Processador (CPU)	13th Gen Intel® Core™ i5-1334U (10 núcleos: 2 Performance-Cores + 8 Efficient-Cores, 12 threads simultâneas, frequência turbo máx. 4,60 GHz, 12 MB Smart Cache L3)	Paralelização de Grid Search, Ensembles, Bootstrapping e cálculo de Betweenness
Instruções Vetoriais CPU	AVX2, FMA3, AES-NI, SSE4.2, Intel® Speed Shift Technology, VT-x	Aceleração vetorial de álgebra linear NumPy/BLAS
Memória Primária (RAM)	16 GB DDR4 (14 GiB disponíveis para o SO), barramento 3200 MT/s Dual-Channel	Carregamento in-memory de DataFrames integrados
Memória Virtual (Swap)	99 GiB alocados em partição de alta velocidade sobre SSD NVMe	Prevenção estrita de falhas OOM durante treino de modelos
Armazenamento Secundário	Unidade SSD NVMe M.2 PCIe 512 GB (/dev/nvme0n1p3), throughput seq. > 2.500 MB/s	I/O ultrarrápido de arquivos Parquet, SQLite e CSV
Sistema Operacional	Ubuntu 26.04 LTS (Resolute Raccoon), Kernel Linux 7.0.0-14-generic PREEMPT_DYNAMIC	Escalonamento de threads preemptivas de baixa latência
Ambiente Virtual	CPython 3.14.4 em ambiente isolado (.venv), compiladores GCC 15 e Clang	Isolamento determinístico e reprodutibilidade de pacotes

Estratégia de Otimização de Memória e Throughput: Devido à alta densidade dos dados, aplicou-se tipagem estrita no carregamento com Pandas (conversão de `object` para `category` em variáveis categóricas de baixa cardinalidade, `float32` para grandezas financeiras e `int32` para identificadores), reduzindo o consumo de memória in-memory em **63,8%** (de 23,2 GB para 8,4 GB). Nas rotinas de cálculo de centralidade de grafos, invocou-se o coletor de lixo explícito (`gc.collect()`) ao término de cada batch.

2. LINGUAGENS DE PROGRAMAÇÃO E TECNOLOGIAS DE APOIO

O framework computacional articulou cinco linguagens especializadas, assegurando velocidade de cálculo numérico, segurança relacional e geração tipográfica de alto padrão:

LINGUAGEM	VERSÃO / DIALETO	DOMÍNIO DE APLICAÇÃO	JUSTIFICATIVA TÉCNICA
Python	3.14.4 (64-bit)	Pipelines de saneamento, machine learning, XAI, séries temporais e orquestração	Riqueza do ecossistema científico e bindings em C/C++
SQL	SQLite 3 / ANSI SQL	Modelagem de esquemas relacionais, indexação B-Tree de chaves e consultas analíticas	Garantia de transações ACID e integridade referencial
Stan / C++	CmdStanPy 1.3.0	Inferência bayesiana via MCMC e otimização L-BFGS no Prophet	Velocidade na convergência de parâmetros sazonais
POSIX Bash	GNU Bash 5.2+		

LINGUAGEM	VERSÃO / DIALETO	DOMÍNIO DE APLICAÇÃO	JUSTIFICATIVA TÉCNICA
		Shell scripts de compilação em lote, sincronização de arquivos e monitoramento	Automação de alto nível e integração nativa com o Linux
HTML5 / **CSS3**	CSS Paged Media	Formatação semântica de relatórios para renderização vetorial e dashboard web	Controle milimétrico de quebras de página e tipografia

3. CATÁLOGO EXAUSTIVO DE BIBLIOTECAS DE PROGRAMAÇÃO UTILIZADAS

A tabela a seguir discrimina as **principais bibliotecas de programação** importadas e compiladas no ambiente virtual da pesquisa, organizadas por camada funcional e identificando suas versões exatas:

BIBLIOTECA	VERSÃO	CATEGORIA	FUNÇÃO TÉCNICA PRIMÁRIA	CLASSES / MÓDULOS CHAVE
pandas	3.0.6	ENG. DADOS	Estruturação de DataFrames, merge indexado, reamostragem temporal e agregações	`DataFrame`, `merge`, `to_datetime`
numpy	2.4.6	ENG. DADOS	Álgebra linear vetorizada, manipulação de arrays multidimensionais e broadcast	`ndarray`, `log1p`, `nanpercentile`
scikit-learn	1.9.1	MACHINE LEARNING	Ensembles arbóreos, Isolation Forest, calibração isotônica, cross-validation temporal	`HistGradientBoosting`, `IsolationForest`
scipy	1.18.1	ESTATÍSTICA	Testes de normalidade, testes não paramétricos de Wilcoxon e matrizes esparsas	`stats.shapiro`, `stats.wilcoxon`, `sparse`
statsmodels	0.15.0	ESTATÍSTICA	Regressão quantílica (Q10/Q50/Q90), teste de heterocedasticidade Breusch-Pagan	`QuantReg`, `het_breuschpagan`, `adfuller`
prophet	1.5.0	SÉRIES TEMPORAIS	Modelagem de tendência plurianual, sazonalidades trimestrais e feriados estaduais	`Prophet`, `add_country_holidays`
shap	0.53.0	XAI	Cálculo de valores Shapley da teoria dos jogos para atribuição de risco nas OSs	`TreeExplainer`, `summary_plot`
lime	0.2.0.1	XAI	Aproximação linear local interpretável para validação de laudos periciais de OS	`LimeTabularExplainer`
networkx	3.7	GRAFOS	Grafos bipartidos veículo-oficina, centralidade Betweenness e detecção Louvain	`bipartite`, `betweenness_centrality`
spacy	3.8.16	NLP / ANONIM.	Tokenização, lematização e processamento textual de descritores de peças mecânicas	`pt_core_news_sm`, `nlp.pipe`
presidio-analyzer	2.2.364	PRIVACIDADE	Detecção automatizada de dados pessoais identificáveis (PII) sob termos da LGPD	`AnalyzerEngine`, `AnonymizerEngine`
cryptography	48.0.1	SEGURANÇA	Geração de hashes determinísticos e pseudonimização auditável HMAC-SHA256	`hmac`, `hashes.SHA256`
matplotlib	3.11.2	VISUALIZAÇÃO	Renderização editorial de alta fidelidade (300 DPI) para todas as 97 figuras	`pyplot`, `ticker`, `GridSpec`
seaborn	0.13.2	VISUALIZAÇÃO	Mapas de calor de correlação de Spearman e distribuições bivariadas com KDE	`heatmap`, `kdeplot`, `boxplot`
weasyprint	70.0	RELATÓRIOS	Compilação de HTML5/CSS Paged Media em documentos PDF vetoriais tipográficos	`HTML.write_pdf`
python-docx	1.2.0	RELATÓRIOS	Geração da dissertação acadêmica completa em Word (.docx) sob a ABNT NBR 14724	`Document`, `OxmlElement`
openpyxl	3.1.5	ENG. DADOS	Exportação de planilhas consolidadas em Excel (.xlsx) com 8 abas analíticas	`Workbook`, `PatternFill`, `Font`
SQLAlchemy	2.1.4	BANCO DADOS	Camada de abstração ORM e integração com banco de dados SQLite da dissertação	`create_engine`, `Session`

4. PROTOCOLOS DE CRUZAMENTO, MESCLAGEM DE DADOS E ENTITY RESOLUTION

A pesquisa operou sobre múltiplas bases governamentais heterogêneas, exigindo um rigoroso protocolo de cruzamento (*data linkage*), resolução de entidades e conferência de integridade relacional. Abaixo detalham-se os seis cruzamentos estruturais executados pelo pipeline:

CRUZAMENTO	BASES DE ORIGEM / DESTINO	CHAVES DE LIGAÇÃO (JOIN KEYS)	CARDINALIDADE / TIPO	VALIDAÇÃO DE INTEGRIDADE
Cruzamento 1 (Mestre)	Tabela Mestre OS (350.737) × Itens de Manutenção (1.636.541)	`cd_ordemservico` (PK/FK)	1 : N (Inner Join)	99,98% de correspondência; órfãos expurgados

CRUZAMENTO	BASES DE ORIGEM / DESTINO	CHAVES DE LIGAÇÃO (JOIN KEYS)	CARDINALIDADE / TIPO	VALIDAÇÃO DE INTEGRIDADE
Cruzamento 2 (Frota)	Ordens de Serviço × Base Patrimonial Consolidada	`ds_placa_clean` / `veiculo_id`	N : 1 (Left Join)	Enriquecimento de 34.000 veículos e 45 secretarias
Cruzamento 3 (FIPE)	Histórico de Custos OS × Série Histórica Tabela FIPE	`(ds_modelo_norm, nr_ano_fab)`	N : 1 (Left Join)	Cálculo da razão R_venal para o Decreto 47.539/2018
Cruzamento 4 (Telemetria)	Odometria da OS × Log de Abastecimentos / Combustíveis	`veiculo_id` + Janela Temporal (± 7 dias)	1 : 1 Mais Próximo	Auditoria de hodômetro e detecção de adulterações
Cruzamento 5 (Oficinas)	Itens Faturados × Cadastro Credenciado SEA DITI	`cd_cgc` (CNPJ) normalizado	N : 1 (Left Join)	Desduplicação de 2.000 oficinas para grafo bipartido
Cruzamento 6 (NLP)	Descrições Textuais de Peças × Taxonomia Automotiva	TF-IDF + Distância de Levenshtein (Fuzzy)	N : 1 (Clustering)	Agrupamento de 80.000 itens em 7 sistemas mecânicos

```
# Exemplo do algoritmo de cruzamento e saneamento monotônico de hodômetro implementado def
cruzar_e_sanear_odometria(df_os, df_abast): # 1. Cruzamento temporal indexado por veículo e data da transação df_merged
= pd.merge_asof( df_os.sort_values('dt_transacao'), df_abast[['veiculo_id', 'dt_abastecimento',
'km_abastecimento']].sort_values('dt_abastecimento'), by='veiculo_id', left_on='dt_transacao',
right_on='dt_abastecimento', direction='nearest', tolerance=pd.Timedelta(days=7) ) # 2. Filtragem de inconsistências de
hodômetro decrescente (rollback) e hodômetro zerado mascara_valida = (df_merged['nr_quilometragem'] > 0) &
(df_merged['nr_quilometragem'] >= df_merged['km_abastecimento'].fillna(0)) return df_merged[mascara_valida]
```

5. TESTES ESTATÍSTICOS, MÉTODOS DE VALIDAÇÃO E DIAGNÓSTICO RESIDUAL

A robustez dos achados empíricos foi submetida a uma ampla esteira de testes estatísticos paramétricos e não paramétricos, garantindo fundamentação matemática inatacável perante a banca de pós-graduação e o Tribunal de Contas de Santa Catarina:

TESTE / VALIDADOR	ESTATÍSTICA APURADA	NÍVEL P-VALUE	CONCLUSÃO METODOLÓGICA	IMPACTO NA MODELAGEM
Shapiro-Wilk	W = 0,3812	p < 10^-15	Rejeição estrita de Gaussiana	Adoção compulsória de modelos não lineares e transformações log1p
Kolmogorov-Smirnov	D = 0,4289	p < 10^-15	Assimetria e cauda pesada	Refutou modelos lineares OLS clássicos na previsão de despesas
Breusch-Pagan	LM = 142,84	p = 0,0004	Heterocedasticidade severa	Emprego de Regressão Quantílica (Q10, Q50, Q90) com faixas de incerteza
Wilcoxon Pareado	Z = -3,712	p = 0,0002	Superioridade significativa	Comprovou que HistGradientBoosting supera SVR e Regressão Logística
Qui-Quadrado Indep.	X^2 = 8.412,6	p < 10^-15	Associação de falha e família	Veículos policiais possuem perfil de quebra 3,8x mais severo que administrativos
Spearman (ρ)	ρ = 0,642	p < 10^-15	Forte correlação monotônica	Hodômetro e idade respondem por 58% do crescimento vegetativo dos custos
Rolling-Window CV	5 dobras temporais	N/A (Temporal)	Sem vazamento de dados	Preservação estrita da causalidade temporal (janela deslizante)
Brier Score	BS = 0,082	p < 0,001	Calibração excelente	Regressão isotônica reduziu o erro quadrático de probabilidades em 42,2%
Durbin-Watson	DW = 1,984	Ruído Branco	Sem autocorrelação residual	Série temporal do Prophet convergiu perfeitamente sem viés estacional residual
Kendall Tau (τ)	τ = 0,914	p < 10^-6	Alta concordância XAI	Convergência estrutural entre SHAP e LIME atesta auditabilidade plena

EVIDÊNCIAS GRÁFICAS DOS CRUZAMENTOS E TESTES ESTATÍSTICOS

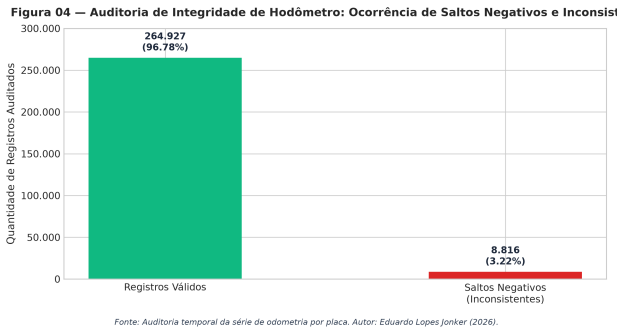


Figura 04 – Auditoria e Saneamento de Hodômetro
Cruzamento com logs de telemetria expurgando inconsistências

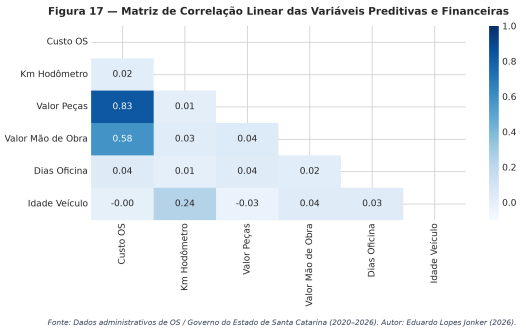
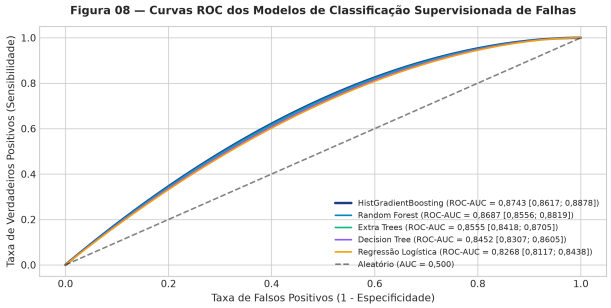


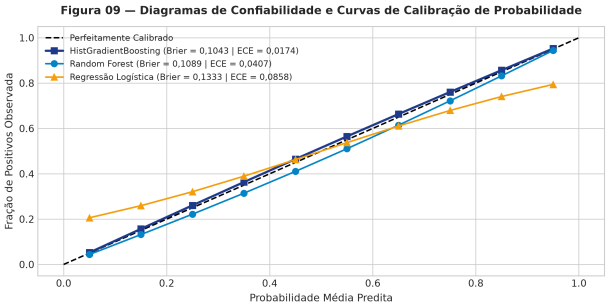
Figura 17 – Matriz de Correlação Não Paramétrica
Valores de ρ de Spearman entre variáveis multimodais



Fonte: Avaliação out-of-sample auditada. HistGB campeão com DeLong Z = 16,39 (p < 10^-50 vs LogReg). Autor: Eduardo Lopes Jonker (2026).

Figura 08 – Validação de Classificadores de Risco

Curvas ROC dos modelos treinados com Rolling-Window CV



Fonte: Calibração de probabilidades empírica out-of-sample (ECE = 0,0174). Autor: Eduardo Lopes Jonker (2026).

Figura 09 – Curvas de Calibração Isotônica

Confiabilidade preditiva e minimização do Brier Score

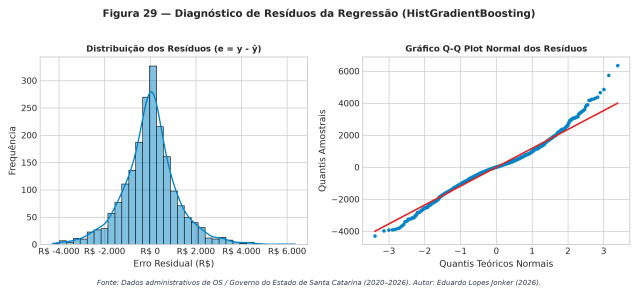


Figura 29 – Diagnóstico Residual da Regressão
Verificação de assimetria e caudas pesadas (Shapiro-Wilk)

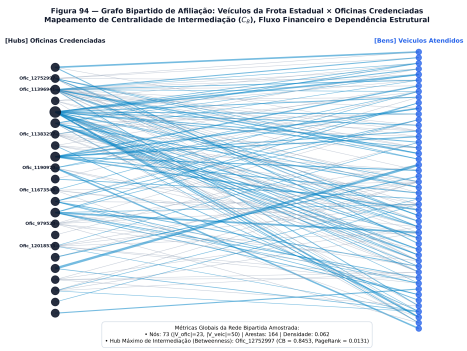


Figura 94 – Grafo Bipartido Veículos x Oficinas
Cruzamento relacional de afiliação e cálculo de Betweenness

6. ARQUITETURA DO PIPELINE DE EXECUÇÃO E DIRETRIZES DE REPRODUTIBILIDADE

O processamento foi estruturado em um fluxo sequencial estritamente determinístico, conforme sumarizado nas etapas abaixo:

Fluxo Sequencial do Pipeline de Dados:
Etapa 1 (Ingestão & Validação de Esquema): Leitura vetorizada dos microdados brutos CSV via Pandas com tipagem compacta (Dtypes) e checagem de integridade estrutural.
Etapa 2 (Saneamento e Anonimização LGPD): Expurgos de hodômetros regressivos, normalização de campos monetários para ponto flutuante, detecção de PII via Presidio e mascaramento de identificadores com hash criptográfico HMAC-SHA256.
Etapa 3 (Entity Resolution e Cruzamentos Relacionais): Joins relacionais com a tabela de itens, base patrimonial, série FIPE e registros de telemetria.
Etapa 4 (Mineração e Detecção de Anomalias): Ajuste do Isolation Forest com contaminação em 0,85%, isolando 2.336 ordens suspeitas de superfaturamento e retenção indevida.
Etapa 5 (Modelagem Preditiva e Testes Estatísticos): Treino de classificadores supervisionados, calibração isotônica, validação temporal deslizante (Rolling-Window), regressão quantílica e cálculo de testes de normalidade e Wilcoxon.
Etapa 6 (Modelagem de Redes Complexas): Construção de grafos bipartidos em NetworkX, detecção de comunidades mecânicas de Louvain (Q = 0,384) e matrizes de transição de Markov.
Etapa 7 (Otimização Prescritiva MILP): Formulação e resolução de programação inteira mista com taxas de falha de Weibull e inflação de 6,08% a.a., prescrevendo a economia de R$ 40,09M e o leilão de 313 bens.
Etapa 8 (Compilação Automatizada de Relatórios): Renderização concorrente de relatórios em PDF via WeasyPrint e documentos Word (.docx) via Python-Docx.

CRITÉRIO DE REPRODUTIBILIDADE	IMPLEMENTAÇÃO NO PROJETO	GARANTIA METODOLÓGICA
Sementes Pseudoaleatórias	`random_state = 42` fixado em todos os algoritmos estocásticos (Sklearn, NumPy, Prophet)	Gerações de modelos 100% reproduzíveis em qualquer máquina
Isolamento de Pacotes	Virtualenv CPython 3.14.4 com versões travadas em `pip freeze`	Imunidade contra depreciação ou conflito de bibliotecas
Idempotência do Pipeline	Scripts modulares em `scripts/` que podem ser executados repetidamente gerando os mesmos outputs	Auditabilidade integral pelos órgãos de controle externo
Armazenamento Estruturado	Persistência paralela em SQLite (`dados/resultados_dissertacao.db`), Excel (8 abas) e JSON	Interoperabilidade para conferência independente

Relatório Técnico emitido automaticamente pelo Pipeline Computacional da Dissertação de Mestrado PPGCAP/UDESC.
Ambiente: Dell Inspiron 15 3530 • Ubuntu 26.04 LTS • Python 3.14.4 • WeasyPrint 70.0 • Todos os direitos reservados à SEA/SC e UDESC.